

APLICACIÓN DE REDES BAYESIANAS PARA EL DIAGNÓSTICO DE ENFERMEDADES RESPIRATORIAS COMÚNES.

Lara Reyes Cruz Joana, Facultad de Matemáticas. Sánchez Chuc Silvia Esther, Facultad de Matemáticas.

Abstract—En este trabajo se habla sobre una de las muchas herramientas que se tienen cuando se habla de Inteligencia Artificial, y ésta es la implementación de las redes bayesianas en el ámbito médico, en otras palabras, la implementación de redes bayesianas para conseguir un diagnóstico de enfermedades lo más acertado posible. Para ello se presentan las nociones básicas acerca de las redes bayesianas así como su funcionamiento implementado en un código en JAVA.

Index Terms—Redes bayesianas, JAVA, diagnóstico médico.

I. INTRODUCCIÓN

EL diagnóstico médico es un ejemplo de toma de decisiones, ya que se requiere tener en cuenta varios aspectos como el historial clínico, los síntomas presentados por el paciente y las pruebas clínicas para determinar qué enfermedad padece una persona. Las decisiones médicas son difíciles de tomar y el resultado del proceso de decisión tiene implicaciones de largo alcance sobre el bienestar o incluso la propia vida de los pacientes.

En la actualidad, existen varias herramientas que ayudan en demasía en el campo de la Medicina. Especialmente los métodos que aprovechan los datos disponibles, la experiencia clínica y que al mismo tiempo tienen como base fundamentos sólidos.

Las redes bayesianas son una de estas herramientas, que son especialmente adecuadas para el modelado de conocimiento incierto, ya que son capaces de describir de manera concisa un problema modelado a través de un conjunto de variables relacionadas entre sí, además de que se puede actualizar la información que se tiene acerca de las variables del problema, cuando se conoce el valor que toma alguna de ellas para casos concretos.

En el campo de la Medicina hay una gran cantidad de datos que se pueden utilizar para diagnosticar un paciente. Con esto llegamos al objetivo de nuestro trabajo, el cual consiste en desarrollar una aplicación para realizar un diagnóstico, lo más acertado posible, de enfermedades respiratorias comunes las cuales se definirán más adelante, utilizando e implementado redes bayesianas.

II. MARCO TEÓRICO

A. Conceptos de teoría de grafos.

Es necesario tener conocimientos sobre los conceptos de una gráfica, así como de las propiedades de las mismas, con el fin de conseguir un mayor entendimiento de resultados e

inferencias posteriores. Para esto, se definirán una serie de conceptos que serán utilizados más adelante.

Gráfica. Una gráfica es un objeto matemático definido como un par $G = (V, A)$, donde $V = V_1, V_2, \dots, V_n$ es un conjunto finito y no vacío y A un conjunto finito, que puede ser vacío. A los elementos de V se les llamará vértices o nodos, a los elementos de A aristas o arcos, descritos como $a = (u, v)$ que conectan a un par de nodos $u, v \in V$.

Vértices adyacentes. Decimos que los vértices u y v en V de la gráfica $G = (V, A)$ son adyacentes si están conectados mediante una arista $a = (u, v)$ en A . Dependiendo de la relación de orden que existe entre los nodos de una gráfica, se puede hablar de dos tipos de arcos: dirigidos (de u a v si el arco (u, v) es un par ordenado) y no dirigidos (si el arco (u, v) no es ordenado), se representan $u \rightarrow v$ y $u - v$, respectivamente. Definidos estos dos tipos de arcos, puede obtenerse la siguiente clasificación de gráficas:

Gráficas dirigidas, no dirigidas o mixtas. Una gráfica que tiene todas sus aristas dirigidas se define como gráfica dirigida, si todas las aristas de la misma son no dirigidas, se denominará gráfica no dirigida y cuando tiene aristas dirigidas y no dirigidas, se dice que la gráfica es mixta.




Fig. 1. Clasificación de gráficas según sus arcos

Camino. Sea $G = (V, A)$ una gráfica. Se dice que una sucesión de aristas $w = a_1, a_2, \dots, a_n$ es un camino en G si $w \subseteq A$ y si $a_i = (v_{i-1}, v_i)$, entonces v_i es adyacente a v_{i+1} .

Observación. Un camino también puede ser expresado en términos de sus vértices.

Ciclo. Se dice que un camino $w = v_0 - v_1 - \dots - v_n$ es un ciclo si el vértice inicial del camino coincide con el vértice final del mismo, es decir, $v_n = v_0$.

Ancestro, descendiente. Un ancestro del vértice v_i es cualquier vértice que tiene un camino hasta v_i . Un descendiente de v_i es cualquier vértice al que se puede ir desde v_i a los conjuntos de ancestros y descendientes de v_i se le denotará como $an(v_i)$ y $de(v_i)$, respectivamente.

Padres, hijos, familia. Si el camino entre los vértices v_i y v_j está compuesto por solamente una arista ($v_i \rightarrow v_j$) se dice que v_i es padre de v_j , y se denota por $pa(v_j) = v_i$, y v_j es hijo de v_i . Se llamará familia del nodo v_i , $fa(v_i)$, al conjunto conformado por el nodo v_i y sus padres $pa(v_i)$, es decir $fa(v_i) = v_i \cup pa(v_i)$.

Gráfica acíclica dirigida. Se dice que una gráfica dirigida $G = (V, A)$ es acíclica cuando no contiene ningún ciclo.





Fig. 2. Gráfica acíclica dirigida (DAG).

En las gráficas acíclicas dirigidas (DAG) es fundamental analizar los tipos de relaciones y conexiones que aparecen entre sus vértices.

- 1) Conexión divergente: Es cuando un vértice es padre de un conjunto de vértices no conectados entre sí.
- 2) Conexión convergente: Es cuando un conjunto de vértices no conectados entre sí son padres de un vértice específico.



(a) Conexión en serie (b) Conexión divergente (c) Conexión convergente

Fig. 3. Conexiones de gráficas acíclicas dirigidas.

B. Conceptos de teoría de probabilidad.

Al igual que con los conceptos fundamentales de la teoría de gráficas, es necesario contar con conceptos básicos de teoría de probabilidad, pues estos son unos principios básicos cuando se emplean las redes bayesianas.

Experimento aleatorio. Un experimento aleatorio es cualquier actividad, proceso o experimento en el cual el resultado es incierto.

Espacio muestral (Ω). El espacio muestral es el conjunto de posibles resultados del experimento aleatorio.

Evento. Cualquier subconjunto del espacio muestral Ω .

Función de probabilidad. Dado un experimento aleatorio con un espacio muestral discreto, una función de probabilidad P es una función en Ω con las siguientes propiedades:

- i) $0 \leq P(\omega) \leq 1$, para todo $\omega \in \Omega$
- ii) $\sum_{\omega \in \Omega} P(\omega) = 1$
- iii) Para todos los eventos $A \subseteq \Omega$, $P(A) = \sum_{\omega \in A} P(\omega)$

Espacio de probabilidad. Un espacio de probabilidad consta de dos elementos (Ω, P) donde Ω es el espacio muestral y P es una función de probabilidad.

Probabilidad condicional. Para los eventos A y B , tal que $P(B) \neq 0$, la probabilidad de A dado B es: $P(A|B) = \frac{P(A, B)}{P(B)}$

Observación $P(A, B) = P(A \cap B)$

Independencia. Dos eventos A y B son independientes si se cumple que $P(A, B) = P(A)P(B)$. Cuando esto sucede escribimos $I_P(A, B)$.

Observación. Equivalentemente, A y B son independientes si $P(A|B) = P(A)$ con $P(A) \neq 0$ y $P(B) \neq 0$. Los eventos que no son independientes se dice que son dependientes.

TEOREMA

Regla de la multiplicación. Supóngase que B_1, B_2, \dots, B_n son eventos en el mismo espacio de probabilidad (Ω, P) , entonces $P(B_1, B_2, \dots, B_n) = P(B_1)P(B_2|B_1)P(B_3|B_1, B_2) \dots P(B_n|B_1, B_2, \dots, B_{n-1})$

Suponiendo que $P(B_1, B_2, \dots, B_{i-1}) > 0$ para $0 \leq i \leq n$.

Partición. Se dice que B_1, B_2, \dots, B_n forman una partición de Ω si $B_i \cap B_j = \emptyset$ si $i \neq j$ y $\bigcup_{i=1}^n B_i = \Omega$. Los eventos que conforman a una partición son llamados mutuamente exclusivos y exhaustivos.

TEOREMA

Ley de probabilidad total. Si A es cualquier evento y B_1, B_2, \dots, B_n es una partición del espacio muestral Ω , entonces $P(A) = \sum_{i=1}^n P(A|B_i)P(B_i)$

TEOREMA

Teorema de Bayes. Si A es cualquier evento con probabilidad $P(A) > 0$ y B_1, B_2, \dots, B_n es una partición tal que $P(B_i) \neq 0 \forall i (1 \leq i \leq n)$, entonces

Distribución de probabilidad conjunta. Dadas dos variables aleatorias X y Y , definidas en el mismo espacio muestral Ω , se define la distribución de probabilidad conjunta de X y Y como: $P(x, y) = P(X = x, Y = y)$

Observación. Dada una distribución de probabilidad conjunta de X y Y se puede calcular la distribución de probabilidad marginal de X $P(x) = P(X = x) = \sum_y P(X = x, Y = y)$.

Partiendo de los conceptos anteriores, definiremos lo que es un modelo gráfico probabilístico, pues este nos ayudará a describir y elaborar redes bayesianas.

Modelo gráfico probabilístico. Un modelo gráfico probabilístico es un par (G, P) donde G es la gráfica que representa la información cualitativa del problema, siendo los vértices las variables del modelo y las aristas las relaciones de dependencia entre dichas variables; y P es el conjunto de distribuciones, que pueden ser condicionadas, mediante las cuales se obtiene la distribución de probabilidad conjunta del problema.

De esta forma llegamos a la definición de red bayesiana.

Las redes bayesianas son modelos gráficos de dependencias para razonamiento probabilístico, en los cuales los nodos representan variables aleatorias y los arco representan relaciones de dependencia directa entre las variables. En una red bayesiana todas las relaciones de independencia condicional representadas en el grafo corresponden a relaciones de independencia en la distribución de probabilidad.

III. METODOLOGÍA

A. Diseño.

De acuerdo a lo que vimos en el apartado anterior, las redes bayesianas son modelos gráficos probabilísticos, los cuales juegan un papel muy importante en el diseño y análisis de sistemas de aprendizaje y actualización de información. Para construir uno de éstos modelos se debe de:

a) Definir el problema a resolver. En esta etapa del proyecto nos enfocamos en encontrar un problema el cual pueda ser resuelto mediante la implementación de redes bayesianas. Escogimos realizar un diagnosticador de enfermedades, sin embargo, nos dimos cuenta que sería algo muy complejo de realizar, además de que se necesitaría la consulta de numerosos expertos e diversas áreas de la medicina, por lo que se redujo el espacio muestral a considerar, siendo éste las enfermedades respiratorias más comunes que las personas padecen. Así el problema queda definido por las cinco enfermedades respiratorias más comunes, en este caso fueron: gripe común, laringitis, bronquitis, asma y pulmonía; que la gente padece junto con los síntomas más significativos de cada una de ellas, entonces lo que se busca en este problema es conocer qué tan probable es que una persona padezca cada una de las cinco enfermedades predispuestas presentando ciertos síntomas.

b) Seleccionar las variables. Esta parte fue un poco más compleja, pues de acuerdo a lo platicado con el experto en el tema, en este caso un médico, resultó que las enfermedades respiratorias cuentan con diversos síntomas, los cuales pueden ser cruciales para la detección de cierta enfermedad. Sin embargo, se optó por escoger los síntomas que varias enfermedades tenían en común y colocarle a cada una de ellas un síntoma que la diferenciara de las demás. Con esto se cabe mencionar que las variables de nuestro problema planteado anteriormente serían las enfermedades con sus respectivos síntomas.

c) Obtención de información relevante. En este caso, para obtener valores cuantitativos, es decir, las probabilidades necesarias para el desarrollo del problema, tuvimos que basarnos de los datos cualitativos puesto que, de acuerdo a lo comentado por los expertos que nos apoyaron en la realización del proyecto; el realizar un diagnóstico médico, se basa en gran medida del criterio del doctor y de las observaciones que él encuentre en el paciente a tratar. Por lo que las probabilidades consideradas para el desarrollo del proyecto, fueron en gran medida inferidas de frases como “Cunado se tienen los los síntomas de gripa común y se empieza a escuchar ronco el paciente, es muy probable que tenga una laringitis”.

d) Construir el modelo gráfico-probabilístico. Conociendo los variables a utilizar, es decir, los síntomas y enfermedades

ya definidas, se procedió a realizar el modelo gráfico o red bayesiana con las probabilidades inferidas de la información obtenida, gracias al experto.

B. Implementación.

Para la implementación del diseño anterior se empleó el software NetBeans, en el cual se creó un programa.

El programa está conformado por dos clases, la clase “NewJFrame” que es la que se encarga de la interfaz y de relacionar los síntomas seleccionados, y la clase “Red”, que es donde se crea la red y se calculan las probabilidades de que se presenten las enfermedades. Se hizo uso de una librería para poder crear y realizar inferencia a las redes, esta librería se llama Jayes. Primero se declara la red utilizando el comando “BayesNet Enfermedades;” y se inicializa de la siguiente forma “Enfermedades = new BayesNet();”, una vez creada la red se declaran los nodos, como por ejemplo el nodo de tos seca se declara de la siguiente forma “BayesNode TosSeca;” y se crea el nodo de “tos seca”, al cual se le asignan valores “True” o “False” y probabilidades dependiendo su valor. Después de haber creado los nodos padres, creamos los nodos hijos, como por ejemplo el nodo hijo “Gripa Común” que tiene 3 padres que son “Tos seca”, “Fiebre de 38° o menos” y “Esgurrimiento nasal”, y se asignan los padres de la siguiente forma “GripaComun.setParentes(Arrays.asList(TosSeca,Fiebre38,EsgurrimientoNasal));”. La probabilidad de cada enfermedad se obtiene a partir de los síntomas que fueron seleccionados en la interfaz gráfica, el programa detecta los síntomas seleccionados y se lo envía a la red, de forma que se hace inferencia y se saca la probabilidad de cada enfermedad.

IV. RESULTADOS

A continuación se presentan los resultados del programa a partir de algunos síntomas seleccionados. En la primera imagen se presentan las probabilidades de se presenten las enfermedades dado que se tienen los siguientes síntomas: tos seca y esgurrimiento nasal. En la segunda imagen se presenta las probabilidades de que se presenten las enfermedades dado que se tiene los siguientes síntomas: tos con flemas, opresión en el pecho y fiebre de 40°.

V. CONCLUSIONES

La realización del proyecto fue un poco más compleja de lo esperado en principio, puesto que calcular las probabilidades de padecer una enfermedad con unos cuantos síntomas no resulta ser lo más óptimo ya que se necesita más estudios y la capacidad de deducción de un profesional en el área para realizar un diagnóstico adecuado.

En cuanto a la implementación de la red bayesiana en el entorno gráfico NetBeans, nos parece que al programa le faltó un poco más de precisión en cuanto al cálculo de las probabilidades de padecer las enfermedades respiratorias.

Para trabajos futuros se observó que para realizar un diagnóstico más acertado es necesaria la introducción de más síntomas para cada enfermedad y definir una probabilidad no sólo basada en el aspecto cualitativo sino también en el aspecto

DIAGNÓSTICO DE ENFERMEDADES RESPIRATORIAS COMÚNES.

Seleccione los síntomas.

☐ Tos seca
☒ Tos con flemas
☐ Temperatura menor o igual a 38°
☐ Temperatura de 38° a 39°
☒ Temperatura mayor o igual a 40°
☐ Escurrimiento Nasal

☐ Ronquera
☐ Sonido al respirar
☒ Opresión en el pecho
☐ Silbido Respiratorio
☐ Cuerpo Cortado

Enviar

Probabilidad de que presenta la enferm...

Gripe Común: 1.0% Asma: 40.0% Pulmonía: 70.0%
 Laringitis: 1.0% Bronquitis: 50.0%

Fig. 4. Programa en ejecución 1

DIAGNÓSTICO DE ENFERMEDADES RESPIRATORIAS COMÚNES.

Seleccione los síntomas.

☒ Tos seca
☐ Tos con flemas
☐ Temperatura menor o igual a 38°
☐ Temperatura de 38° a 39°
☐ Temperatura mayor o igual a 40°
☒ Escurrimiento Nasal

☐ Ronquera
☐ Sonido al respirar
☐ Opresión en el pecho
☐ Silbido Respiratorio
☐ Cuerpo Cortado

Enviar

Probabilidad de que presenta la enferm...

Gripe Común: 70.0% Asma: 40.0% Pulmonía: 1.0%
 Laringitis: 1.0% Bronquitis: 1.0%

Fig. 5. Programa en ejecución 2

cuantitativo. Se espera mejorar la implementación de la red bayesiana en algún entorno de programación, si se realizan trabajos futuros.

VI. ANEXO

VII. REFERENCIAS

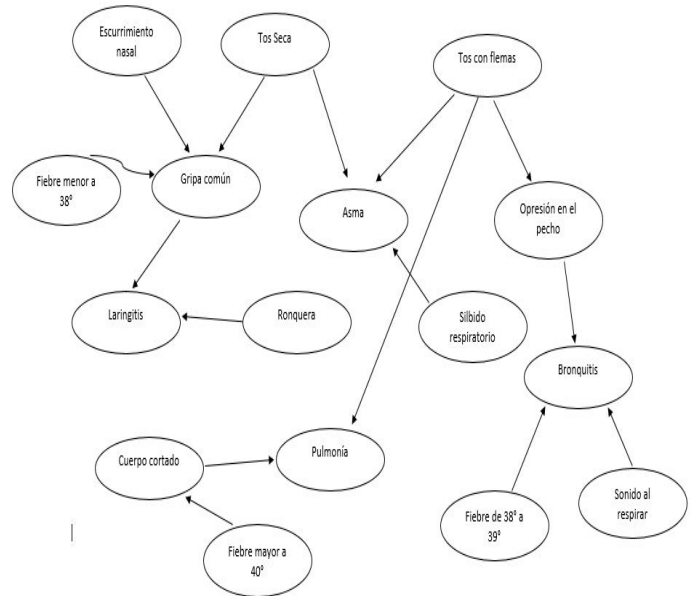


Fig. 6. Red Bayesiana